

Mini-rapport synthétique

Segmentation Clientèle (Modèle RFM)

1 Méthode

Les deux feuilles du fichier *UCI Online Retail II* ont été concaténées pour couvrir deux années de transactions. Les données ont ensuite été nettoyées en retirant les doublons exacts, les lignes sans identifiant client, les annulations, les retours, les quantités non positives et les prix non positifs. Les annulations ne sont pas ignorées conceptuellement : elles sont comptées dans l'audit de nettoyage et proposées comme variante de robustesse.

Les variables RFM (Récence, Fréquence, Montant) sont calculées au niveau client à partir des achats positifs.

- **Récence** : nombre de jours entre la dernière commande et le lendemain de la dernière date observée.
- **Fréquence** : nombre de factures positives distinctes.
- **Montant** : chiffre d'affaires total généré par le client.

Les distributions initiales étant fortement asymétriques, les variables ont fait l'objet d'un traitement spécifique : elles sont plafonnées au 99^e percentile, transformées logarithmiquement (via la fonction `log1p`), puis standardisées avant l'étape de clustering.

2 Choix du nombre de segments

Les valeurs de k (nombre de clusters) allant de 2 à 8 ont été comparées en s'appuyant sur plusieurs métriques : l'inertie intra-classe, le score de silhouette, la stabilité (mesurée par l'Indice de Rand Ajusté, ARI) et la taille minimale des segments.

Le choix final retient $k = 5$. Cette configuration offre une typologie marketing suffisamment riche, distinguant :

1. Les Champions
2. Les Actifs rentables
3. Les Nouveaux occasionnels
4. Les Clients à risque
5. Les Clients endormis / à faible valeur

Ce choix s'avère plus actionnable qu'un découpage trop grossier et nettement plus lisible qu'une segmentation trop fragmentée.

3 Résultat opérationnel

Le tableau de synthèse final détaille, pour chaque segment : son effectif, sa part dans le chiffre d'affaires global, ses moyennes RFM, les principaux pays d'origine et les produits dominants.

Les recommandations marketing en découlant sont volontairement différenciées afin d'optimiser l'allocation des ressources :

- **Fidélisation forte** pour les *Champions* (programmes VIP, accès en avant-première).
- **Consolidation** pour les *Actifs rentables* (ventes croisées, montée en gamme).
- **Onboarding (intégration)** pour les *Nouveaux occasionnels* (parcours de bienvenue, incitation au deuxième achat).
- **Réactivation** pour les *Clients à risque* (offres ciblées, enquêtes de satisfaction).
- **Relance automatisée limitée** pour les *Clients endormis/faible valeur* (pour minimiser les coûts d'acquisition tout en maintenant un contact).

4 Limites

Il convient de rappeler que le clustering n'est pas une vérité absolue. Ses résultats dépendent intrinsèquement de la qualité du nettoyage initial, de la période d'observation retenue, de la méthode de transformation des variables et de l'algorithme choisi.

Pour être pérenne, la segmentation doit :

- Être testée et suivie dans le temps.
- Être régulièrement confrontée aux retours des équipes métier.
- Être mise en relation avec des indicateurs de campagne concrets : taux d'ouverture, taux de conversion, taux de désabonnement, marge générée et satisfaction client.

Enfin, une attention particulière doit être portée à l'éthique de la personnalisation. Il est crucial d'éviter toute pratique de tarification opaque (dynamic pricing discriminatoire) ou tout traitement injuste ou pénalisant envers certains segments de clientèle.