

Segmentation clients RFM

Mini-rapport synthétique

Togo AI Summer School

Membres du groupe : AKAYA Eniwinéwé Henri ; ALKISSANKDEI T. Djamal ; BLAISE Mouné Tchoubou ; LARE V. Donné ; METO Kemi Gédéon ; OPEKOU-DOUDOE Christian ; TORA Dkawlma Emmanuel.

Origine du projet. L'analyse initiale résulte d'un travail collectif réalisé lors du Togo AI Summer School. À partir de ce socle, le porteur du dépôt a poursuivi le projet à titre personnel : approfondissement des diagnostics, ajout d'une API FastAPI, d'un assistant n8n avec mémoire PostgreSQL et d'une interface web. Ces extensions sont distinguées du travail initial du groupe.

1 Objectif et méthode

L'objectif est de regrouper les clients selon leurs achats observés afin de formuler des hypothèses de campagnes différenciées. La segmentation décrit l'historique ; elle ne prédit ni le départ d'un client ni sa rentabilité.

Les deux feuilles du jeu *UCI Online Retail II* sont concaténées. Le nettoyage supprime les doublons exacts, les lignes sans identifiant client ou date exploitable, les factures d'annulation et les quantités ou prix non positifs du périmètre principal. Les retours sont conservés séparément pour l'analyse de sensibilité. Les achats retenus couvrent le **1^{er} décembre 2009 au 9 décembre 2011**, sur **5 878 clients**. La référence est le **10 décembre 2011**.

Pour chaque client i , les indicateurs sont :

- R_i : nombre de jours depuis son dernier achat valide à la date de référence ;
- F_i : nombre de factures positives distinctes dans la fenêtre ;
- M_i : somme des montants d'achats positifs, en livres sterling (GBP), sans déduction des retours.

Une faible récence signifie un achat récent, pas nécessairement un nouveau client. Le montant ne mesure pas la marge, car les coûts ne sont pas disponibles.

Les trois variables sont plafonnées à leur 99^e percentile, transformées par $\log(1+x)$ puis standardisées :

$$z_{ij} = \frac{\log(1 + \min(x_{ij}, q_{0,99,j})) - \mu_j}{\sigma_j}.$$

Les paramètres sont appris sur la population historique. Cette préparation réduit l'influence des valeurs extrêmes et évite que les montants dominant mécaniquement les distances. K-means utilise une graine fixée à 42 et 100 initialisations. La livraison documente scikit-learn 1.9.0.

2 Choix du nombre de segments

Les valeurs de k de 2 à 8 sont comparées avec l'inertie, la silhouette, Calinski-Harabasz, Davies-Bouldin, les tailles des groupes et la stabilité ARI entre dix graines. La silhouette, Calinski-Harabasz et Davies-Bouldin préfèrent ici $k = 2$. Leur compromis par moyenne des rangs préfère également 2 ; le coude géométrique indicatif suggère $k = 4$.

Le choix final de $k = 5$ **est commercial**, et non un optimum statistique démontré. Les profils et la matrice de correspondance entre $k = 4$ et $k = 5$ permettent d'examiner les différences observées. L'intérêt d'une campagne supplémentaire reste à mesurer face à une stratégie à quatre groupes.

3 Résultats et propositions marketing

Le montant total des achats positifs retenus est de **17 685 460,64 GBP**. Les parts ci-dessous utilisent ce même dénominateur. Les noms des groupes sont relatifs à cette partition et décrivent leurs profils moyens ; ils ne caractérisent pas uniformément chaque client du groupe.

Segment	Clients	CA (%)	R (j)	F
Champions	587	59,18	18,00	28,56
Actifs à montant élevé	1 250	24,12	58,36	8,56
Achats anciens	1 335	10,10	303,15	3,56
Achats récents occasionnels	1 126	4,35	32,30	2,50
Achats anciens à faible montant	1 580	2,25	416,98	1,23

R et F : moyennes de récence et de fréquence. Les pourcentages sont arrondis. Source : `tableau_synthese_segments.csv`.

Segment	Montant moyen (GBP)
Champions	17 829,92
Actifs à montant élevé	3 412,10
Achats anciens	1 337,73
Achats récents occasionnels	683,75
Achats anciens à faible montant	252,15

Les Champions représentent environ 10 % des clients et 59,18 % du montant positif. Cette concentration justifie une attention particulière, sans prouver une marge supérieure ou une fidélité future. Les achats anciens ne constituent pas, à eux seuls, une preuve d'attrition. De même, les achats récents occasionnels ne renseignent pas la date du premier achat du client.

Actions proposées, à tester plutôt qu'à considérer comme acquises :

1. **Champions** : tester un programme relationnel et des accès anticipés. Mesurer le réachat et les désabonnements face à un groupe témoin.
2. **Actifs à montant élevé** : proposer des produits complémentaires. Comparer le montant supplémentaire et le coût de contact ; une hausse de CA ne suffit pas à démontrer une hausse de marge.
3. **Achats anciens** : tester une relance sur un échantillon et comparer le taux de réachat à celui d'un groupe témoin.
4. **Achats récents occasionnels** : encourager un prochain achat par une sélection pertinente, sans supposer qu'il s'agit du deuxième achat.
5. **Achats anciens à faible montant** : limiter la pression de contact et tester une relance peu coûteuse. Mesurer le réachat, les désabonnements et le coût par réponse avant généralisation.

Pour comparer les stratégies à quatre et cinq segments, les groupes de test devraient être randomisés, avec un budget, un horizon et une pression de contact comparables. Le bénéfice commercial ne sera établi qu'après mesure, par exemple de la conversion ou de la marge incrémentale si les coûts sont collectés. Aucun résultat de campagne n'est disponible dans ce projet.

4 Vérification de l'effet des retours

Une seconde segmentation utilise le montant net sur les **mêmes clients**, avec la même fenêtre, les mêmes R et F et $k = 5$. Les lignes à quantité négative et prix positif sont déduites du montant, qu'elles portent ou non un numéro de facture commençant par C. Les annulations à quantité positive restent ambiguës et ne sont pas transformées arbitrairement en montants négatifs. Les clients ayant uniquement des retours sont hors de la population comparée.

Les plafonds et la standardisation appris sur les achats positifs restent figés. La transformation du montant net conserve son signe :

$$g(M) = \text{sign}(M) \log(1 + |M|).$$

La valeur absolue intervient uniquement dans le logarithme : les montants nets négatifs ne deviennent pas des dépenses positives. K-means est réentraîné sur cette variante. Les groupes sont appariés en maximisant les clients communs avant de compter les migrations.

Les retours retenus représentent **1 031 016,71 GBP**, soit **5,83 %** des achats positifs. L'ARI entre les deux partitions vaut **0,5810** et **1 671 clients (28,43 %)** changent de groupe après appariement. Les retours modifient donc la partition dans ce protocole. Les répétitions sur dix graines documentent la sensibilité aux initialisations ; elles ne constituent ni un intervalle de confiance ni un test de significativité.

Cette expérience isole l'effet monétaire : les retours ne sont pas rapprochés facture par facture et peuvent concerner des achats antérieurs à la fenêtre. Des clients sans retour peuvent aussi migrer lorsque les centres changent. Les noms alignés des groupes nets sont des repères, pas des profils métier validés.

5 Extensions de la plateforme et limites

L'API sert les résultats et classe un profil RFM par proximité aux centroïdes figés, sans réentraînement ni ajout aux données. Les trois dates de la fenêtre et de référence sont obligatoires. Le mode historique exige les dates du modèle ; une autre période impose une simulation explicite, sans annualisation ni probabilité de confiance. La cohérence des dates ne garantit pas la pertinence sur une autre population.

L'interface permet la recherche, le filtrage et l'export global des clients. L'assistant n8n consulte les résultats agrégés et utilise une mémoire PostgreSQL associée à la session. Une recette de 14 scénarios couvre notamment les chiffres, la concision, la mémoire, les pannes et les injections. Les tests techniques ne remplacent pas une recette réelle des réponses du fournisseur. La synchronisation contrôle le modèle, les CSV et la fiche documentaire avant livraison.

Sans vérité terrain, les indices internes, la stabilité et les profils ne prouvent pas l'efficacité commerciale. La saisonnalité, l'ancienneté des clients, les grossistes et les choix de nettoyage peuvent influencer les résultats. L'usage doit limiter les sollicitations, permettre le retrait, protéger les données individuelles et éviter les traitements discriminatoires ou les prix personnalisés injustifiables.

Traçabilité. Résultats issus de `m1/index.ipynb`, des tables de `m1/outputs/` et de `docs/current-model.md`. Modèle : `rfm-3ab5423591563489`. Livraison : `bundle-229a31b580c84328`. Ce rapport constitue une synthèse de cette livraison ; ses chiffres doivent être revus après un nouvel entraînement.